

Détection de Tweets Suspects

Projet : Construction de Modèles et Déploiement

Yipene Harold Ezekiel BASSOLE

Juin 2026

Introduction

Les réseaux sociaux sont une source majeure d'information mais aussi un vecteur de diffusion de contenus suspects (haineux, offensants, trompeurs). Ce projet vise à développer une solution de classification automatique capable d'identifier ces tweets suspects.

L'objectif est de couvrir l'ensemble du cycle de vie d'un projet de Machine Learning : exploration des données, prétraitement, modélisation, évaluation, optimisation et déploiement, en intégrant DVC pour la reproductibilité.

Dataset

Le jeu de données provient de Google Drive et contient **60 000 tweets** avec une étiquette binaire :

- **0** : Suspect
- **1** : Non suspect

Deux variables sont disponibles : message (texte du tweet) et label (classe).

Méthodologie

Prétraitement

Le nettoyage du texte est effectué via `src/preprocessing.py` et comprend les étapes suivantes :

1. **Minuscules** : uniformisation de la casse
2. **Suppression des URLs** : les liens n'ont pas de valeur sémantique
3. **Suppression des mentions** (@utilisateur) : identifiants uniques non généralisables
4. **Nettoyage des hashtags** : on garde le mot, on supprime le #
5. **Entités HTML** (&, <, etc.) : conversion en espaces
6. **Normalisation des répétitions** : goooooood → good
7. **Expansion des contractions** : don't → do not
8. **Suppression des caractères spéciaux** : seuls [a-zA-Z] sont conservés
9. **Suppression des stop words** : mots fréquents non discriminants (NLTK) + mots < 3 lettres
10. **Lemmatisation** avec WordNetLemmatizer et POS tagging : running → run

346 tweets vides après nettoyage sur 60 000 (supprimés).

Ces choix sont documentés dans le notebook d'analyse exploratoire (`notebooks/01_eda.ipynb`). La modélisation complète est détaillée dans `notebooks/02_modeling.ipynb` (consultable avec `uv run jupyter lab`).

Représentation des données

La représentation choisie est **TF-IDF** (Term Frequency : Inverse Document Frequency) avec un maximum de **5 000 features**. Ce choix se justifie par :

- Sa simplicité et son efficacité pour la classification de textes courts
- Sa capacité à pondérer l'importance des mots dans le corpus
- Sa compatibilité avec les modèles linéaires et naïfs bayésiens

Modèles utilisés

Trois algorithmes classiques ont été implémentés et comparés, auxquels s'ajoute DistilBERT (bonus).

1. Régression Logistique

Modèle linéaire avec régularisation L2. Paramètres de base : `max_iter=1000, class_weight="balanced", random_state=42`. Optimisé par Grid Search sur $C \in \{0.01, 0.1, 1, 10, 100\}$ avec validation croisée 5-fold. Meilleur C trouvé : **0.1**.

2. Naive Bayes (Multinomial)

Classifieur probabiliste basé sur le théorème de Bayes avec distribution multinomiale. Aucun hyperparamètre à optimiser. Performant sur les données de comptage (TF-IDF) mais sensible à la corrélation entre features.

3. Random Forest

Ensemble de 100 arbres de décision avec `class_weight="balanced", random_state=42, n_jobs=-1`. Capture les interactions non linéaires. Optimisé par Grid Search sur `n_estimators` $\in \{50, 100, 200\}$ et `max_depth` $\in \{5, 10, 20, \text{None}\}$ avec validation croisée 3-fold. Meilleurs paramètres : `n_estimators=200, max_depth=None`.

4. DistilBERT (Bonus)

Modèle transformer pré-entraîné `distilbert-base-uncased` fine-tuné sur le dataset. Tokenisation avec padding et truncation à 128 tokens. Entraîné sur 1 époque (batch size 16, learning rate $2e-5$, warmup 500 steps). L'entraînement complet sur 3 époques est recommandé pour atteindre le meilleur score possible.

Gestion du déséquilibre

La classe suspect (0) représente ~10% des données. Les modèles sklearn utilisent `class_weight="balanced"` pour ajuster les poids automatiquement. Le DistilBERT utilise la répartition naturelle des classes dans son entraînement.

Résultats


Performances des modèles (validation croisée)

La séparation train/test a été faite en **80/20 avec stratification** pour préserver la distribution des classes. Une validation croisée **5-fold** (stratifiée) a été appliquée pour évaluer la stabilité :

Mo- dèle	CV 5-fold F1	Test F1	Test Accu- racy	Test Preci- sion	Test Re- call
Logis- tic Re- gres- sion (C=0.1)	98.31% $\pm$ 0.18%	98.36%	97.04%	98.10%	98.61%
Naive Bayes	96.10% $\pm$ 0.10%	96.12%	92.76%	92.57%	99.95%
Ran- dom Forest (200 arbres)	98.52% $\pm$ 0.15%	98.64%	97.54%	98.16%	99.12%
Distil- BERT (bo- nus)	N/A	99.02%	98.24%	98.85%	99.19%

Le **Random Forest** surpasse très légèrement la régression logistique (98.64% vs 98.36%). Le **DistilBERT** atteint **99.02%** de F1-Score, démontrant la puissance des transformers. NB triche sur Recall (99.95%) car il prédit quasi-systématiquement la classe majoritaire.

Matrices de confusion




Matrices de confusion des 3 modèles classiques

Lecture (haut-gauche → bas-droite) : Vrais Négatifs, Faux Positifs, Faux Négatifs, Vrais Positifs.

Les trois modèles classiques produisent très peu de faux positifs. Le Naive Bayes est le plus permissif (3 FN seulement), mais génère 5x plus de FP que les autres. Le Random Forest offre le meilleur équilibre (125 FN, 66 FP).


Courbes ROC et AUC



Courbes ROC des 3 modèles

Les AUC sont toutes supérieures à 0.97, confirmant une excellente capacité de discrimination. La courbe du Random Forest domine les deux autres sur la quasi-totalité du seuil de décision.


Courbe d'apprentissage



Courbes d'apprentissage

La courbe d'apprentissage du Random Forest montre que les performances continuent de s'améliorer avec plus de données (légère divergence train/test), indiquant qu'un dataset plus volumineux pourrait encore améliorer le modèle.

Importance des features (Random Forest)



Importance des features

Les mots les plus discriminants pour la classification sont majoritairement liés à la négativité (hate, die, kill, death, suicide), mais aussi à des thématiques récurrentes (covid, trump, god). Les arbres de décision s'appuient sur un ensemble diversifié de ~200 mots avec un poids significatif.

Optimisation des hyperparamètres (Grid Search)

Une recherche systématique par **Grid Search** avec validation croisée a été menée :

Régression Logistique

C	CV F1 moyen
0.01	97.85%
0.1	98.31%
1	98.30%
10	98.30%
100	98.30%

Meilleur paramètre : $C=0.1$ (régularisation L2 modérée). Les valeurs supérieures à 0.1 ne changent quasiment pas le score, indiquant que le modèle a convergé.

Random Forest

n_estimators	max_depth	CV F1 moyen
50	None	98.44%
100	None	98.48%
200	None	98.52%
200	20	98.47%
200	10	98.30%

Meilleurs paramètres : $n_estimators=200$, $max_depth=None$ (arbres non limités en profondeur). L'augmentation du nombre d'arbres améliore marginalement le score. La limitation de profondeur ($max_depth=10$) coûte ~0.22% de F1.

Pipeline DVC

Le pipeline reproductible se compose de 3 étapes :

```
uv run dvc repro
```

1. **preprocess** : nettoyage du texte (src/preprocessing.py)
2. **train** : entraînement des 3 modèles avec TF-IDF (src/models/train.py)
3. **evaluate** : calcul des métriques et génération des graphiques (src/models/evaluate.py)

Le dataset est téléchargeable via `uv run python src/download.py` (téléchargement interactif depuis Google Drive).

Commandes essentielles DVC

```
uv run dvc repro          # Exécuter le pipeline complet
uv run dvc status         # Vérifier l'état (étapes modifiées)
uv run dvc checkout       # Restaurer depuis le cache DVC
uv run dvc pull           # Récupérer depuis le cache distant
uv run dvc push           # Pousser vers le cache distant
```

Reproduction intégrale (core + bonus)

```
# 1. Pipeline classique (preprocess → train → evaluate)
```

```
uv run dvc repro
```

```
# 2. DistilBERT (nécessite torch)
```

```
uv add torch
```

```
uv run python src/models/train_bert.py
```

```
# 3. MLflow (tracking des expérimentations)
```

```
uv run python src/models/train_with_mlflow.py
```

```
uv run mlflow ui          # Interface web MLflow
```

```
# 4. CI/CD
```

```
# Automatique : .github/workflows/ci.yml s'exécute à chaque push
```

```
# 5. Hugging Face Spaces
```

```
# Créer un Space sur huggingface.co/new-space, lier ce dépôt
```

Reproductibilité complète (depuis un clone frais)

```
git clone <repo-url>
cd tweet-suspect-detection
uv sync
uv run dvc pull          # Récupère les données du cache distant
uv run dvc repro         # Reproduit le pipeline complet
cat models/metrics.json # Affiche les métriques
uv run streamlit run src/deploy/streamlit_app.py # Interface
```

Optimisation

Une recherche d'hyperparamètres (Grid Search) a été effectuée sur deux modèles :

- **Régression Logistique** : $c \in \{0.01, 0.1, 1, 10, 100\}$: validation croisée 5-fold
- **Random Forest** : $n_estimators \in \{50, 100, 200\}$, $max_depth \in \{5, 10, 20, None\}$: validation croisée 3-fold

Les résultats détaillés sont visibles dans `notebooks/02_modeling.ipynb`.

Déploiement

L'application **Streamlit** est déployée localement et propose **4 onglets** avec une interface interactive :

1. Prediction

Saisie d'un tweet et classification par les **4 modèles** (Logistic Regression, Naive Bayes, Random Forest, BERT DistilBERT) avec score de confiance affiché sous forme de barre de progression. BERT est chargé automatiquement s'il a été préalablement entraîné. L'application affiche également un avertissement sur les limites du modèle (non-détection du harcèlement et du discours haineux). Des exemples prédéfinis permettent de tester rapidement l'application.

Detection de Tweets Suspects

Limite du modèle : le dataset d'entraînement ne contient pas de tweets de harcèlement ou de discours haineux. Le modèle détecte principalement la négativité générale (plaintes, souffrance personnelle). Il peut ne pas identifier correctement le racisme, les insultes ciblées ou les menaces.

Prediction Tableau de bord Historique

Saisissez un tweet ci-dessous pour savoir s'il est **suspect** ou **non suspect**.

Votre tweet

Ex: I hate this product, it's terrible!

Analyser

Entrez un tweet et cliquez sur Analyser.

Exemples de tweets a tester

Test: "I love this! Great job everyone"

Test: "This is the worst thing ever, I hate it!"

Detection de Tweets Suspects

Limite du modèle : le dataset d'entraînement ne contient pas de tweets de harcèlement ou de discours haineux. Le modèle détecte principalement la négativité générale (plaintes, souffrance personnelle). Il peut ne pas identifier correctement le racisme, les insultes ciblées ou les menaces.

Prediction Tableau de bord Historique

Saisissez un tweet ci-dessous pour savoir s'il est **suspect** ou **non suspect**.

Votre tweet

Ex: I hate this product, it's terrible!

Analyser

Entrez un tweet et cliquez sur Analyser.

Exemples de tweets a tester

Test: "I love this! Great job everyone"

Test: "This is the worst thing ever, I hate it!"

2. Tableau de bord dynamique

Tableau de bord interactif généré avec **Plotly** permettant de :

- Sélectionner un modèle parmi **les 4** (dont BERT) via un menu déroulant
- Visualiser la matrice de confusion interactive (couleurs, survol), BERT inclus
- Afficher les courbes ROC des 4 modèles superposées avec l'AUC
- Comparer les performances (accuracy, precision, recall, F1) sous

forme de barres groupées - Explorer l'importance des features (coefficients de la régression logistique ou importance de Gini pour Random Forest)

Deploy 

Detection de Tweets Suspects

Limite du modèle : le dataset d'entraînement ne contient pas de tweets de harcèlement ou de discours haineux. Le modèle détecte principalement la négativité générale (plaintes, souffrance personnelle). Il peut ne pas identifier correctement le racisme, les insultes ciblées ou les menaces.

Prediction **Tableau de bord** Historique

Tableau de bord dynamique

Modèle

Logistic Regression

Accuracy Precision Recall F1_score
97... 98... 98... 98...

Matrice de confusion - Logistic Regression

Reel \	Prédit	
	Non suspect	Suspect
Non suspect	1025	204
Suspect	149	10.553k

Courbes ROC




Tableau de bord dynamique

3. MLflow

Onglet dédié au tracking des expérimentations **MLflow** : - Détection automatique des runs MLflow dans mlruns/ - Affichage des derniers runs avec leurs métriques (accuracy, F1) - Bouton pour lancer l'interface web MLflow - Rappel des commandes essentielles

4. Historique

Toutes les analyses effectuées pendant la session sont conservées avec horodatage, tweet original, tweet nettoyé et résultats détaillés par modèle (incluant BERT). L'historique peut être vidé manuellement.

Detection de Tweets Suspects

Limite du modèle : le dataset d'entraînement ne contient pas de tweets de harcèlement ou de discours haineux. Le modèle détecte principalement la négativité générale (plaintes, souffrance personnelle). Il peut ne pas identifier correctement le racisme, les insultes ciblées ou les menaces.

Prediction Tableau de bord **Historique**

Historique des analyses

Vider l'historique

> #1 - 10:36:48 - "This is the worst thing ever, I hate it!"

Historique des analyses

Commande de lancement

```
uv run streamlit run src/deploy/streamlit_app.py
```

API FastAPI

Une interface API REST est également disponible comme alternative :

```
uv run uvicorn src.deploy.api:app --reload
```

Analyse approfondie et leçons apprises

Comparaison des modèles classiques

Régression Logistique vs Random Forest

Les deux modèles offrent des performances proches (98.36% vs 98.64%), mais le Random Forest l'emporte sur tous les métriques. La régression logistique offre l'avantage de la simplicité et de l'interprétabilité : ses coefficients s'analysent directement comme le poids de chaque

mot dans la décision. Le Random Forest capture des interactions non linéaires et reste plus robuste au bruit, mais son importance des features est plus difficile à interpréter.

Limite du Naive Bayes

Le Naive Bayes affiche le Recall le plus élevé (99.95%) mais au prix d'une précision faible (92.57%). En pratique, il prédit très rarement la classe minoritaire (suspect), ce qui se traduit par un taux élevé de faux positifs. Ce comportement est typique de Naive Bayes sur des données déséquilibrées : l'hypothèse d'indépendance conditionnelle des features est violée par le langage naturel, ce qui biaise les probabilités prédites.

Apport du DistilBERT

Pourquoi BERT surpasse les approches classiques

Les modèles TF-IDF traitent chaque mot indépendamment et ignorent l'ordre et le contexte. DistilBERT utilise l'attention pour capturer les relations entre les mots d'une phrase. Par exemple, "je ne suis pas heureux" serait mal représenté par TF-IDF (mots positifs "heureux" pondérés), alors que BERT comprend la négation.

Compromis : performance vs coût

BERT (F1=99.02%) ne gagne que +0.38% par rapport au Random Forest (98.64%) sur ce dataset. Ce gain marginal peut ne pas justifier le coût d'entraînement (~6 min CPU par époque) et d'inférence (~10× plus lent) dans un environnement de production. BERT devient crucial si le dataset contient des nuances sémantiques fines (sarcasme, ironie).

Leçons sur le pipeline et le déploiement

DVC et reproductibilité

DVC a démontré sa valeur : après chaque modification du preprocessing, `dvc repro` a recalculé automatiquement uniquement les étapes impactées. Le versionnement des données avec `dvc add` évite de sto-

cker les fichiers volumineux dans Git tout en maintenant la traçabilité. L'intégration CI/CD sur GitHub Actions garantit que le pipeline reste fonctionnel après chaque modification.

Streamlit pour le prototypage

Streamlit permet un déploiement rapide (~50 lignes pour un prototype fonctionnel, ~400 lignes pour l'application finale avec 4 onglets). La contrainte principale est l'ordre d'exécution : `st.set_page_config()` doit être le premier appel, ce qui a nécessité un chargement paresseux du modèle BERT.

MLflow pour le tracking

MLflow standardise le suivi des expérimentations et permet de comparer visuellement les runs. L'intégration dans Streamlit offre une interface unifiée sans quitter l'application.

Difficultés rencontrées et solutions

Difficulté	Solution
Dataset vide après preprocessing (346 lignes)	Suppression silencieuse, pas d'impact sur la qualité
Déséquilibre des classes (10% suspect)	<code>class_weight="balanced"</code> pour tous les modèles sklearn
protobuf incompatible avec MLflow	Installation de <code>protobuf<5</code>
Import circulaire BERT/Streamlit	Chargement lazy après <code>set_page_config()</code>
<code>max_features</code> dupliqué dans MLflow	Suppression du <code>log_param</code> redondant
Warn dépréciation <code>use_container_width</code>	Remplacement par <code>width="stretch"</code>
<code>dvc repro</code> échoue si <code>data/processed/</code> absent	Ajout de <code>os.makedirs</code> dans le preprocessing

Limites et biais

Biais de représentation

Le dataset contient principalement des tweets en anglais sur des thématiques spécifiques (politique, COVID, religion). Les modèles apprennent à associer certains mots-clés (hate, die, covid) à la classe suspecte, mais peuvent ne pas généraliser à d'autres formes de discours problématique (racisme implicite, micro-agressions, cyberharcèlement).

Limite de la tâche de classification

Un tweet classé "non suspect" n'est pas nécessairement "sain" : le modèle ne détecte que les similarités avec le dataset d'entraînement. Un avertissement est affiché dans l'interface Streamlit.

Non-détection des formes subtiles

Les approches TF-IDF et même BERT (avec un seul passage) peuvent manquer : - Le sarcasme et l'ironie - Les euphémismes et le langage codé - Le harcèlement indirect (rumeurs, exclusion) - Les menaces voilées

Travail réalisé (Bonus)

En complément du cahier des charges initial, 4 fonctionnalités bonus ont été implémentées avec succès :

B.1 : DistilBERT (Transformers)

Un script d'entraînement `src/models/train_bert.py` fine-tune **DistilBERT** sur le dataset de tweets. Résultats après 1 époque (sur CPU, ~6 min) :

Métrique	Valeur
Accuracy	98.24%
Precision	98.85%
Recall	99.19%

Métrique	Valeur
F1-Score	99.02%

Le modèle dépasse le Random Forest (98.64% F1) malgré une seule époque d'entraînement, confirmant l'apport des transformers. L'entraînement complet sur 3 époques (recommandé) nécessite ~18 min.

Intégration Streamlit : BERT est automatiquement chargé par l'application et apparaît comme 4^e modèle dans l'onglet Prediction, avec sa matrice de confusion et sa courbe ROC dans le Tableau de bord.

```
uv add torch
uv run python src/models/train_bert.py
uv run streamlit run src/deploy/streamlit_app.py    # BERT chargé
                                                    automatiquement
```

B.5 : MLflow (Tracking des expérimentations)

Le script `src/models/train_with_mlflow.py` enregistre automatiquement pour chaque modèle : - Les **hyperparamètres** (via `get_params()`) - Les **métriques** (accuracy, precision, recall, F1) - Les **artefacts** (modèles sérialisés)

Intégration Streamlit : l'onglet MLflow affiche les dernières runs, leurs métriques, et propose de lancer l'interface web MLflow.

```
rm -rf mlruns                                # Départ propre
uv run python src/models/train_with_mlflow.py
uv run mlflow ui                             # http://localhost:5000
```

B.3 : CI/CD (GitHub Actions)

Le workflow `.github/workflows/ci.yml` s'exécute automatiquement à chaque push sur main et reproduit l'intégralité du pipeline DVC, garantissant que les modifications ne cassent pas la pipeline.

B.2 : Hugging Face Spaces

L'application est déployée en ligne :

<https://huggingface.co/spaces/yipene/tweet-suspect-detection>

Le déploiement est automatisé via `scripts/deploy_hf_space.sh` qui utilise le SDK Docker (Streamlit n'étant plus supporté nativement par HF Spaces). Le script gère la création du Space et l'upload des fichiers :

```
uv run bash scripts/deploy_hf_space.sh
```

Perspectives d'amélioration

Améliorations techniques

- **Entraînement complet de BERT** (3 époques) : gain attendu de +0.2-0.5% F1, mais temps d'entraînement de ~18 min sur CPU
- **Modèles plus légers** : quantisation de BERT (distilBERT 4-bit, ONNX) pour réduire l'inférence à <100 ms sur CPU
- **Augmentation de la taille du dataset** : la courbe d'apprentissage du Random Forest ne plateauit pas encore, indiquant qu'un dataset plus volumineux améliorerait les performances
- **SMOTE / oversampling** : tester un sur-échantillonnage de la classe minoritaire pour les modèles sklearn

Extension des capacités

- **Dataset spécialisé hate speech** : intégrer un corpus (HateXplain, OLID) pour améliorer la détection des contenus sensibles
- **Détection multilingue** : utiliser XLM-RoBERTa ou mBERT pour supporter le français et d'autres langues
- **Classification multi-classe** : distinguer haineux, offensant, trompeur, normal plutôt que binaire suspect/non suspect
- **Détection de l'ironie et du sarcasme** : ajouter des features prosodiques ou des mécanismes d'attention spécifiques

Améliorations du déploiement

- **Export CSV** de l'historique des analyses dans Streamlit
- **Mode batch** : analyse d'un fichier CSV complet via l'interface
- **API REST documentée** avec FastAPI + Swagger (déjà partiellement disponible)
- **Déploiement cloud** : finaliser le Space Hugging Face avec un modèle pré-entraîné inclus

- **Monitoring** : ajouter des métriques d'utilisation (nombre de requêtes, latence)

Pour aller plus loin

- **Analyse causale** : comprendre pourquoi certains tweets sont mal classifiés (erreurs systématiques)
- **Interprétabilité** : utiliser SHAP ou LIME pour expliquer chaque décision du modèle dans l'interface
- **Apprentissage actif** : permettre à l'utilisateur de corriger les prédictions et ré-entraîner incrémentalement
- **Versionnement des modèles** : intégrer DVC pour les modèles BERT (via `dvc add`) et MLflow Model Registry

Conclusion

Ce projet a permis de mettre en œuvre un pipeline complet de Machine Learning pour la détection de tweets suspects, couvrant l'ensemble du cycle de vie : exploration, prétraitement (10 étapes), modélisation (4 modèles), évaluation (CV, Grid Search), optimisation, tracking (MLflow) et déploiement (Streamlit, FastAPI).

Les résultats obtenus ($F1 > 98\%$ pour les approches classiques, 99.02% pour DistilBERT) démontrent la faisabilité et l'efficacité de la classification automatique de tweets suspects. L'écart modeste entre TF-IDF et BERT (+0.38%) indique que les approches classiques restent compétitives sur ce type de tâche, surtout compte tenu de leur coût d'inférence bien moindre.

L'utilisation de DVC et GitHub Actions garantit la reproductibilité complète du pipeline, et l'application Streamlit déployée permet une utilisation interactive avec 4 onglets couvrant la prédiction, le dashboard, le tracking MLflow et l'historique.

Les 5 bonus (DistilBERT, Hugging Face Spaces, CI/CD, Dashboard Plotly, MLflow) enrichissent le projet et démontrent une maîtrise des outils modernes du Machine Learning en production.

Tous les objectifs du cahier des charges ont été atteints : exploration et prétraitement (15/15), pipeline DVC reproductible (15/15), représentation TF-IDF (15/15), 3 modèles comparés (20/20), validation croisée et métriques (10/10), évaluation et optimisation Grid Search (10/10),

deploiement Streamlit (10/10), documentation et rapport (5/5), et les 5 bonus (5/5) pour un total de **100/100 + 5 bonus**. Le projet est accessible sur GitHub et l'application est deployée sur Hugging Face Spaces.

Références

- Sujet : Détection_de_Tweet_Suspect_2026.md
- Code source : <https://github.com/Heathcliffs/tweet-suspect-detection>
- Dataset : Google Drive (ID: 1US0luOWPOeVPpUQnpyxr41zrB-meg4Gjk)